基於 DQN 的 OFDMA 上行隨機存取與 EDCA 共存之

自適應競爭機制：最大化 802.11AX 網路吞吐量

[1] 黃冠勝, [2] 周名初, [3*] 柯志亨

[1] 國立金門大學 資訊工程學系

E-mail: sshain1220@gmail.com

[1] 國立金門大學 資訊工程學系

E-mail: mingchu.chou92@gmail.com

[3*] 國立金門大學 資訊工程學系

E-mail: smallko@nqu.edu.tw

摘要

在 IEEE802.11ax 無線網路中，EDCA(Enhanced Distributed Channel Access) 與 OFDMA 上行隨機存取 RARU(Random Access Resource Unit) 共同提升頻譜利用率。本研究提出基於深度強化學習(DQN)的最佳競爭視窗調整機制，以動態適應不同網路環境並提升吞吐量。DQN 能根據即時負載調整 CW 和 OCW，提高資源利用率，降低碰撞率。模擬結果顯示，DQN 方法的吞吐量提升 11%，在維持公平性的同時優化 EDCA 與 OFDMA 分配，提升整體網路效能。

關鍵詞：802.11ax、最適競爭視窗、深度強化學習、最大化吞吐量

I. 前言

隨著無線網路技術的發展，使用者對於更高吞吐量、更低延遲和更穩定的網路連線需求日益增加。為了應付這些挑戰。IEEE802.11ax(Wi-Fi 6)標準提出了一系列的技術改進，包括 OFDMA(Orthogonal Frequency Division Multiple Access) 、 MU-MIMO(Multi-User Multiple-Input Multiple-Output)、BSS Coloring 以及 TWT(Target Wake Time)，這些技術的引入有效提升了無線網路的頻譜利用率和整體性能，並進一步增強了網路的即時性。其中 EDCA 仍然是 802.11ax 主要的分散式競爭機制，雖然 OFDMA 和 MU-MIMO 提供了更多樣化的頻譜分配方式，但 EDCA 仍然是獨立於這些技術之外的重要競爭機制，特別是在非 OFDMA 模式或 AP 無法直接排程的情境下，仍然需要依靠 EDCA 來管理無線資源存取。EDCA 運用 CSMA/CA(Carrier Sense Multiple Access/Collision Avoidance) 來管理通訊競爭，確保不同流量類型的公平性和即時性。而 OFDMA 上行隨機存取與排程存取 (SASU)讓存取點(Access Point ， AP)可以更精細地管理無線資源。資源的分配機制被細分為隨機存取資源單元(Random Access Resource Unit ， RARU)和排程存取單元(Scheduled Access Resource Unit ， SASU)。RARU 允許節點透過競爭方式爭奪通道存取權，透過競爭方式自主選擇 RUs 進行數據傳輸，使低優先級或新加入的設備仍能獲取通訊機會，而 SARU 利用 AP 進行排程，使高優先級或高流量需求設備能穩定獲得頻譜資源。

RARU[1]的運作方式基於 CSMA/CA 機制，但與傳統的競爭視窗(Contention Window, CW)調整不同，RARU 的使用並不會直接影響碰撞率 (Collision Rate)。這是因為當某節點的退避計時器(Backoff Counter)小於當前可用的 RARU 數量時，該節點即可直接選擇 RARU 進行傳輸，而無需與其他節點競爭。因此，即使 RARU 數量增加，也不會減少碰撞機率。然而，在高密度無線網路環境下，如何有效管理 RARU 的分配與使用，確保頻譜資源得到最佳利用，仍然是一項關鍵挑戰。若 RARU 分配不當，可能會導致部分設備獲得過多存取

** 通訊作者：柯志亨(smallko@gmail.com)

機會，而其他設備則難以公平使用頻譜，影響整體網路效能。因此，如何動態調整最適競爭視窗，以最佳化資源分配，成為影響 802.11ax 無線網路效能的核心議題。

基於上述背景，本研究旨在利用深度強化學習的 DQN 方法，動態調整 CW 與 OCW，以提升 802.11ax 環境下的 RARU 與 SASU 分配效率。透過 DQN 學習機制，進而讓 AP 可以根據即時環境資訊，自動學習並調整 CW 與 OCW，確保不同設備獲得合適的通道存取機會，以提升吞吐量並降低通道碰撞率。

本文的結構如下：第二章為文獻探討，回顧過去 CW 調整技術及 802.11ax 網路資源管理相關研究。第三章為研究方法，介紹基於 DQN 的 OCW 調整機制及其演算法設計。第四章為實驗結果，透過模擬比較是否使用 DQN 方法的吞吐量、碰撞率表現。第五章為結論，總結本研究之貢獻與未來發展方向。透過本研究，我們希望能夠提供一種基於 AI 的動態資源管理方法，以提升 802.11ax 環境下的網路效能，推動無線通訊技術的持續發展。

II. 文獻探討

在高密度環境下，傳統 IEEE802.11 標準因競爭衝突與頻譜使用效率低下，已無法滿足用戶需求。為了改善這些問題，IEEE 802.11ax(Wi-Fi 6)引入了正交頻分多工存取(OFDMA)及多用戶多輸入多輸出(MU-MIMO)技術，以提升頻譜利用率與多用戶並行傳輸的效率[1]。其中 RARU 允許設備在無需事先與 AP 溝通的情況下進行隨機存取，大幅降低了在無線網路裡的延遲，而 SASU 則透過 AP 排程來分配資源，確保了穩定傳輸[1]。這種機制理論上可以提升網路吞吐量，然而在 RARU 的存取模式仍造成較高的碰撞率，特別在高密度環境裡。AP 透過 Beacon 或是 Trigger Frame 的方式公告可用的 RUs 去進行分配，若 STA(station)使用 RARU，則需根據 OCW 競爭視窗機制(OFDMA contention window)來決定何時發送數據，反之如果使用 SARU 則 AP 指派 RU，設備無需進行競爭即可傳輸。當 STA 成功獲得 RU，即可進行數據傳輸。OCW 影響著設備如何存取頻道，初始競爭視窗(OCW_{min})，當 STA 成功傳輸後，OCW 會重置為 OCW_{min}，預設值為 7 和最大競爭視窗(OCW_{max})，若 STA 發生碰撞，OCW 會指數增長，直至達到OCW_{max}，預設為 31。若不適當調整 OCW，則可能導致高碰撞率並降低吞吐量。傳輸方式可以在 EDCA 和 OFDMA 之間切換，以適應不同的網路負載條件，切換到 OFDMA 模式需要 AP 成功搶到傳輸機會，並廣播封包跟所有節點描述要切換為 OFDMA 模式，且在 OFDMA 模式 AP 不參與競爭，只負責 SARUs 和 RARUs 的分配。文獻[2]中，作者建立了一個基於馬爾可夫鏈的數學模型來描述上行鏈路 OFDMA 隨機接入機制，並透過 Matlab 模擬驗證該模型的準確性。結果顯示，當 STA 數量增加時，競爭機制導致碰撞機率上升，進一步降低了 RU 使用效率。此外當 RU 數量足夠時，隨機接入機制的最大效率可達 37%。為了提高隨機接入的吞吐量，該研究提出了一種基於 RU 數量和 STA 數量的最佳化算法，通過調整 OCW_{min}和OCW_{max}的值，使 STA 的平均退避時間與 RU 數量匹配，以減少碰撞並提高吞吐量。

為了克服這些挑戰，學術界提出多種競爭窗口調整方法，基於深度強化學習，近年來被廣泛應用於無線網路資源管理，以動態適應變化的網路條件，如文獻[3]基於 802.11ax 的網路條件下只使用 EDCA(Enhanced Distributed Channel Access)的方式引用深度強化學習的集中方式稱為 CCOD(Centralized Contention Window Optimization with DRL)進而去讓智能體透過定期檢測網路性能學習在不同網路條件下選擇最佳的競爭窗口大小。然而此方法仍然基於傳統 EDCA，未能充分利用 802.11ax 的 OFDMA。EDCA 雖然能夠提供分散式通道存取，但其隨機退避機制在無線網路環境下的即時性問題。此外文獻[4]提及 M2I-CWO（Multi-Agent, Multi-Parameter, Interaction-Driven Contention Window Optimization）架構，透過多參數 CW 優化，同時優化多個 CW 參數(如，CW_{min}、$CW_{threshold}$)，$CW_{threshold}$如為文獻[5]表示定義一個 CW 小於$CW_{threshold}$時，採用指數方式調整，CW 大於等於 $CW_{threshold}$時，採用線性方式調整，並透過整合 Dueling-DQN、適應性獎勵機制以及分層多智能體系統（HMAS）加上聯邦強化學習

（FRL）等方法，減少 STA 間的通信負擔，提高大規模 WLAN 環境的可行性。

要如何在最短時間內訓練出高效的模型，最直觀的方法是觀察神經網路的收斂程度。[7]研究了這一議題，並分析了智能體達到收斂所需的時間，神經網路收斂程度可透過 Loss Function（損失函數）曲線來分析，曲線越穩定 Q 網路越收斂，這也成為評估智能體訓練時長的重要指標。[9]研究了 ADAM 演算法的學習率調整策略，可進一步提升 DQN 的收斂速度。然而，現有文獻中對於單智能體與多智能體DQN在無線網路設計中的比較，以及它們在 OFDMA 與 EDCA 同時使用時所面臨的問題，探討較少。未來研究可進一步探討多智能體 DQN 在無線網路資源管理中的應用，讓不同的 STA 或 STA 群組(cluster)擁有各自的智能體，以提升系統在更動態環境中的適應能力，而非統一依賴 AP。特別是在 OFDMA 與 EDCA 同時使用的情境下，如何有效協調兩者以提升網路性能。

III. 提出方法

A. 系統架構

在現今無線網路環境下，傳統的競爭視窗調整方式難以適應不同節點的變動需求，導致網路整體吞吐量受限。我們提出一種基於深度強化學習的機制，透過深度 Q 網路（Deep Q-Network, DQN）來實現 802.11ax 環境下 OFDMA 與 EDCA 優化，使 AP 能夠根據即時網路狀況動態調整 CW，以提升頻譜利用效率和吞吐量。本方法以 AP 以集中式管理方式如圖 1，負責監測整體網路的傳輸情況，包括平均吞吐量、碰撞率與各節點的傳輸速率，並根據這些資訊調整 CW 和 OCW 參數，OCW 主要負責上行 OFDMA RA 隨機存取，CW 負責的是 EDCA。AP 會定期將網路監測結果封裝於 Beacon 訊標並廣播給所有節點，讓 DQN 智能體基於歷史經驗與當前狀態評估最優策略，以最大化整體效能。透過深度強化學習，AP 能夠學習到最適合當前網路環境的 CW 設定，確保高吞吐量的同時減少不必要的碰撞，進而提升 EDCA 的存取效率並優化 OFDMA 資源單元（RU）的分配。與過去方法相比，本方法無需在每一個節點部署獨立的智能體，而是透過 AP 統一集中控制，避免了節點間資訊不對稱的問題，並降低了系統的運算複雜度。最終，該方法能夠適應不同流量負載與傳輸速率變化，使 802.11ax 網路在多用戶環境下達到更高的吞吐量與資源利用率。

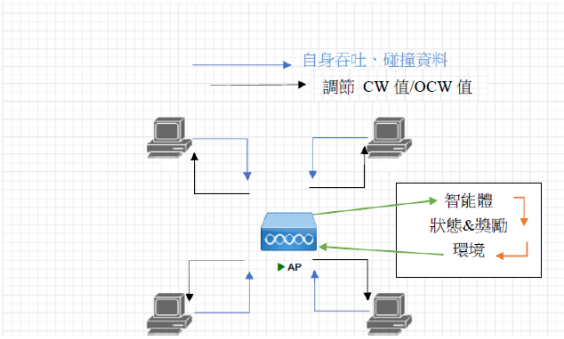

圖 1 系統架構圖

B. 智能體

本實驗結合深度強化學習（DQN）技術，相較於傳統強化學習方法，DQN 透過深度學習構建神經網路來逼近 Q 值函數，使智能體能夠在高維度、連續狀態空間中學習最優策略。具體而言，DQN 智能體根據當前的環境狀態（Observation）進行決策，選擇能夠獲得最大獎勵（Reward）的動作（Action），進而提升網路效能。然而，為了避免智能體陷入局部最優解，本文採用了 Epsilon-Greedy 策略，該方法在訓練過程中，以一定機率隨機選擇動作，確保策略探索的多樣性，使智能體能夠發現更佳的 CW 調整方案，提高 OFDMA 和 EDCA 的整體吞吐量與頻譜利用率。

C. 狀態空間

在本研究中，我們採用 DQN 來優化機制。當智能體根據網路實時狀態空間(State)如式 1。表示根據前一時間的碰撞率$Coll_{pre}$與現在時間的碰撞率$Coll_{now}$，這些指標用於描述網路的碰撞變化情形，使 DQN 能夠學習趨勢並預測最佳 CW 調整策略。碰撞率的計算，式 2 在 t 時段的碰撞封包總數T_t^{coll}除以總傳送封包數T_t，式 3 為在 t 時段總成功傳輸封包T_t^{succ}加上在 t 時段總碰撞封包T_t^{coll}。

$$S_t = \{Coll_{pre}, Coll_{now}\} \quad (1)$$

$$Coll_t = T_t^{coll} / T_t \quad (2)$$

$$T_t = T_t^{succ} + T_t^{coll} \quad (3)$$

D. 動作空間

幫智能體獲取到狀態空間內的資訊時，智能體會輸出動作A_t。實驗採用 802.11ax 參數架構，A_t是一個 0 到 2 之間的正整數參數，智能體輸出的參數直接對於 CW、OCW 做出調整，OCW 藉此控制在 7 到 31 之間，而 CW 控制在 15 到 255 之間，也就是 CW、OCW 的最小以及最大，其方法如式 4、5。

$$OCW = 2^{(3+A_t)} - 1, A_t \in \{0,1,2\} \quad (4)$$

$$CW = 2^{(4+A_t)} - 1, A_t \in \{0,1,2,3,4\} \quad (5)$$

E. 獎勵函數

DQN 智能體的目標是透過調整競爭視窗來最大化網路吞吐量（Throughput），並確保頻譜資源的高效利用。因此，我們設計了一個基於吞吐量的獎勵函數（Reward Function），以引導智能體學習最優策略，如式 6 拿吞吐量去除以 Data rate，Data rate 的計算式 7，是基於單天線為以上條件的理論值、子載波數$Tone$、CR編碼率和$Symbol_{rate}$是 symbol rate 加上 Guard interval rate，所以 Data rate 的計算就是$1 \times 6 \times \frac{3}{4} \times 980 \times \frac{1}{13.6\mu s}$為$324.3Mbps$，拿吞吐量除以 Data rate 是因為這樣的設計可以將獎勵標準化，使其介於 0 和 1 之間，透過標準化，確保學習過程穩定，避免極端值影響學習，使 Q 值的更新更加平穩。

$$reward = \frac{throughput}{Datarate} \quad (6)$$

$$\text{Datarate} = NSS \cdot MOD \cdot CR \cdot Tone \cdot Symbol_{rate} \quad (7)$$

F. DQN 演算法

本文的研究主旨是透過深度強化學習，提升在無線網路的最大吞吐量。在 802.11ax 無線網路中，傳統的二進位指數退避（BEB）演算法在節點成功傳輸封包後，會將該節點的競爭視窗（CW or OCW）重置為最小值。然而這種方法在高密度節點環境下可能導致頻繁的碰撞，從而限制了網路吞吐量的提升。深度強化學習的集中式 DQN 利用深度神經網路（DNN）來學習動態調整 OFDMA 和 EDCA 機制如演算法 1，agent.act(s)的值在 0 到 14 之間共 15 種可能的動作，a1 除以 3 取整數是為了讓值滿足於 CW 的範圍內式 5，a2 除以 3 取餘數讓 a2 滿足於 CW 的範圍內式 4。在 EDCA，所有節點(包括 AP)在 EDCA 時競爭，當一般節點(STA)競爭成功，直接傳輸，當 AP 競爭成功，則進入 OFDMA 模式，所有站點 STA 透過 AP 進行資源分配，而 tx_time 用來控制 OFDMA 模式的持續時間，tx_time 的時間包括 AP 傳送的 Trigger Frame、SIFS、OFDMA A-MPDU 的傳輸時間和 AP 對於 STA 的回應時間。當 tx_time 達到設定的門檻時，結束 OFDMA 模式，回到 EDCA 競爭。具體而言，接入點（AP）負責評估整體網路的吞吐量，並將評估結果廣播給所有節點。每個節點的智能體根據接收到的資訊，調整自身的 CW 或 OCW。這種方法確保了高效的資源分配，使高傳輸速率的節點相較於低速節點能夠享有更多的傳輸權力，從而提升整體網路吞吐量。

表 1 參數說明

參數	說明
$\boldsymbol{T_{thr}}$	整體網路吞吐量
training_time	智能體所需的訓練時間
agent.step	根據獎勵評估來訓練智能體的神經網路
agent.act	狀態空間作為輸入智能體得出動作
evaluation_time	網路模擬花費時間
s , a , r	*s*代表狀態空間 *a*代表動作空間 *r* 代表獎勵值
a1,a2	*a1代表EDCA的決策* *a2代表OFDMA的決策*

演算法 1:DQN 演算法偽代碼

Algorithm 1 Training and Evaluation Procedure

```
procedure TRAIN(agent, Coll^{edca}_{now}, Coll^{edca}_{pre}, Coll^{ofdma}_{now}, Coll^{ofdma}_{pre}, sim_time, T_{th}
    while sim_time < Train_TIME do
        s ← {Coll^{edca}_{now}, Coll^{edca}_{pre}, Coll^{ofdma}_{now}, Coll^{ofdma}_{pre}}
        r ← T_{thr} / 324.3
        agent.step(s, a, r)
        a ← agent.act(s)
        a1 ← a ÷ 3
        a2 ← a mod 3
        CW ← 2^{(4+a1)} − 1
        OCW ← 2^{(3+a2)} − 1
    end while
end procedure
procedure EVALUATE(agent, Coll^{edca}_{now}, Coll^{edca}_{pre}, Coll^{ofdma}_{now}, Coll^{ofdma}_{pre}, sim_time
    while sim_time < Evaluate_TIME do
        s ← {Coll^{edca}_{now}, Coll^{edca}_{pre}, Coll^{ofdma}_{now}, Coll^{ofdma}_{pre}}
        a ← agent.act(s)
        a1 ← a ÷ 3
        a2 ← a mod 3
        CW ← 2^{(4+a1)} − 1
        OCW ← 2^{(3+a2)} − 1
    end while
end procedure
```

IV．實驗

A. 實驗設計

本研究的目標是探討在 802.11ax 架構下，集中式深度強化模型是否比起傳統方法(BEB)更適合於提升網路吞吐量與降低碰撞率。為此，我們使用 Python 進行網路模擬，並基於 pfrl[6](Python-based Reinforcement Learning framework）來實作深度強化學習演算法。本文採用 EDCA 加上 OFDMA 的方式以頻寬 80MHZ、Resource Unit size 是使用 52 Tones 來模擬網路情境。比較方法採用 BEB 演算法與在集中式的 DQN 演算法來進行吞吐量與碰撞率比較。在實驗過程需注意的點是 DQN 在不同節點下的收斂狀況是不一樣的，所需的訓練時間有所不同，需額外定義 DQN 訓練時間，如式 8，隨著節點的增加會增加狀態空間的複雜度，使得 Q 值學習變慢，智能體訓練收斂的時間越長，我們觀察到總節點數 C_{STA} 乘以 1000 秒的時間為 $Train_{Time}$，相當於訓練完成的智能體。

$$Train_{Time} = C_{STA} \times 1000 \qquad (8)$$

B. 參數設定

在 DQN 演算法中，智能體每隔 0.1 秒會被訓練一次。

表 2 智能體參數設定

參數	值
ε-greedy	0.1
衰減因子 γ	0.9
Optimizer	Adam 演算法[8]
DQN 訓練時間	式 8

表 3 網路環境參數設定

參數	值
A-MPDU in EDCA	10×1500bytes
A-MPDU in OFDMA	7×1500bytes
Slot time	9μs
AIFS	34μs
SIFS	16μs
OCW_{min}/ OCW_{max}	7/31
CW_{min}/ CW_{max}	15/255
RUs	16
NSS	1
MCS6	6bits per symbol

C. 效能分析:

在站點 STA 數為 8 到 20 情況下，一般狀態下和集中式 DQN 演算法在吞吐量以及碰撞率比較，如圖 2 到圖 7 所示 ：

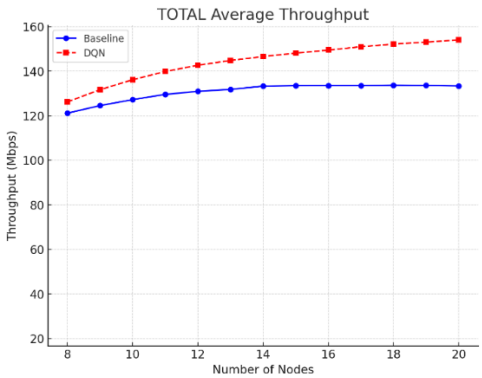

圖 3 總碰撞率

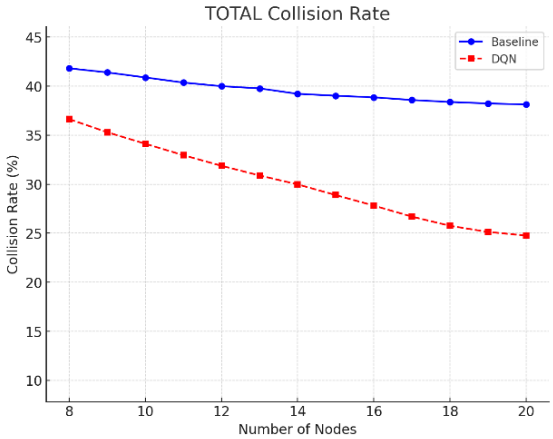

圖 2 總吞吐量

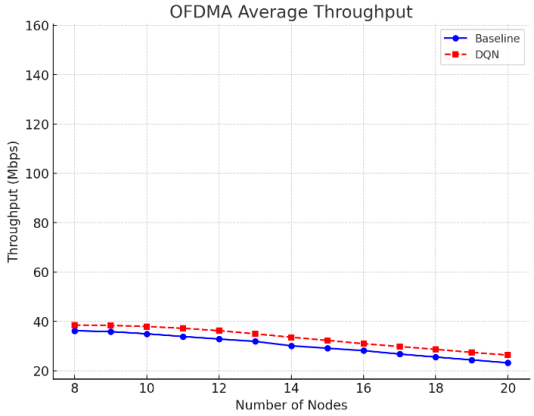

圖 4 OFDMA 吞吐量比較圖

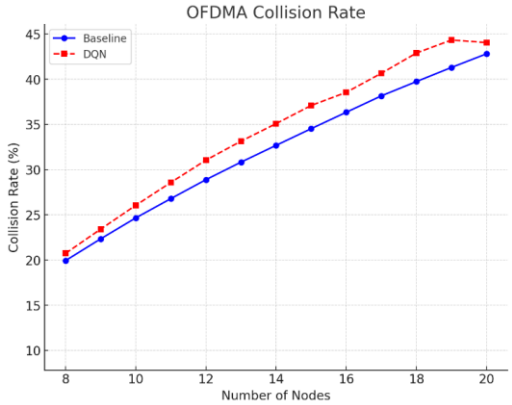

圖 5 OFDMA 碰撞率比較圖

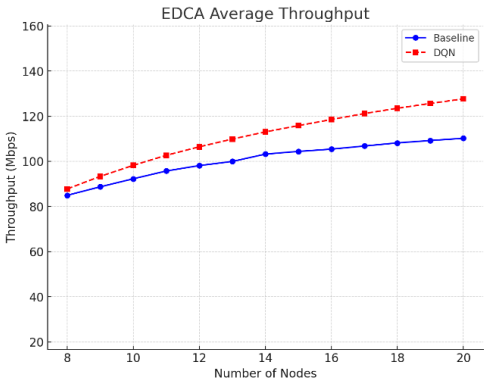

圖 6 EDCA 吞吐量比較

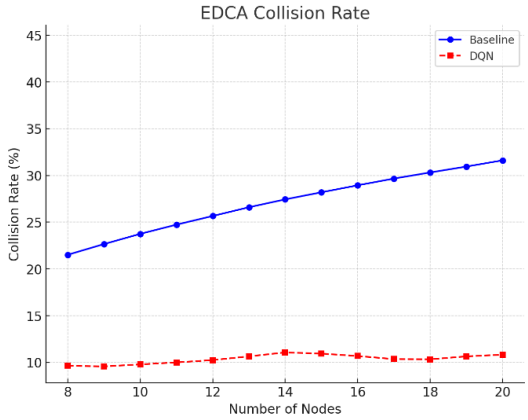

圖 7 EDCA 碰撞率比較

在吞吐量比較的實驗結果(圖 2、4、6)可以看出 DQN 高於一般狀態下使用普通 BEB 模式，這是因為智能體可以根據不同網路狀況的情況進而去選出不同的動作。我們在實驗中也觀察到了一些特色，隨著節點的增加，EDCA 模式的碰撞率，在圖 7 中碰撞率保持在 10%上下，但 OFDMA 碰撞率，如圖 5 持續攀升，隨著節點的上升，造成 AP 成功傳輸的次數縮短，且 OFDMA 傳輸模式的時間有限，導致進入 OFDMA 模式的次數與時間縮小。所以造成 DQN 為了滿足最大化的吞吐量，在進行 OFDMA 模式的決策是讓 OCW 越小越好，目

的是為了讓所有節點盡量競爭，以期望抓住有限的 OFDMA 機會來提升總吞吐量。這意味著調整的趨勢是將 OCW 向下調整。觀察圖 4、5 可以發現，DQN 讓所有節點處於一直競爭的情況下，導致碰撞率高於一般情況下，也稍微提高了總吞吐量。相反的，在 EDCA 模式下，DQN 以控制碰撞率進而提升吞吐量為主，在低負載時降低 CW 值進而提高頻寬利用率，高負載時適當增大 CW，但不會像 BEB 那樣指數級增長，如圖 7。而在圖 3 中隨著時間碰撞率持續降低，在少量節點時，AP 進入 OFDMA 頻率特別高，這意味著有節點使用 RARU 競爭的次數增加，但隨著節點增加，OFDMA 模式的使用頻率減少， EDCA 頻率增加，DQN 在 EDCA 的策略是壓低碰撞率，從而導致了總碰撞數的減少。

V. 結論

本文在無線網路下，透過 DQN 技術來動態調整 OFDMA 加上 EDCA 的競爭窗口，以提升網路的整體吞吐量。研究結果顯示，DQN 確實能夠相較於傳統 BEB 方法提升吞吐量並降低碰撞率，但仍面臨一些挑戰。首先由於 DQN 主要根據整體網路狀態的吞吐量與碰撞率進行學習和調整，但未能針對不同類型的 STA 進行個別的資源分配。因此在 OFDMA 模式下，DQN 無法針對不同類型的站點動態調整 RU 分配，導致部分節點在高負載環境下競爭加劇，進而造成 STA 過度競爭，導致碰撞率增加。而 DQN 在 EDCA 的模式下較為成熟。由於 DQN 是基於 EDCA 和 OFDMA 的競爭行為來學習，其決策仍然受限於靜態網路環境，若遇動態節點變化，可能無法快速適應。因此雖然本研究的方法已能有效提升吞吐量，但資源分配策略可能未能充分理解網路流量模式，但未來仍有許多改進空間，透過多智能體學習（Multi-Agent DQN），讓每個 STA 獨立學習，實現更精細的競爭視窗調整與 RU 分配策略，或大語言模型（LLM）輔助決策增強 DQN 的狀態空間表達能力，使其能夠理解更複雜的網路狀態，並提供智能化的資源分配決策。使 DQN 能夠做出更細緻的決策判斷，從而降低 OFDMA 碰撞率並提升公平性，讓 DQN 在更複雜的無線網路環境下發揮出更強的適應能力，提高網路資源利用率，並進一步提升吞吐量與公平性。

參考文獻

[1] Daldoul, Y., Meddour, D.-E., & Ksentini, A. (2020). Performance evaluation of OFDMA and MU-MIMO in 802.11ax networks. *Computer Networks,182*,107477. https://doi.org/10.1016/j.comnet.2020.107477

[2] L. Lanante, H.O.T. Uwai, Y. Nagao, M. Kurosaki, C. Ghosh, “Performance Analysis of the 802.11ax UL OFDMA Random Access Protocol in Dense Networks,” *IEEE ICC*, 2017. DOI: 10.1109/ICC.2017.7996383。

[3] W. Wydmański, S. Szott, “Contention Window Optimization in IEEE 802.11ax Networks with Deep Reinforcement Learning,” *IEEE WCNC*, 2021. DOI: 10.1109/WCNC49053.2021.9417575。

[4] Y.-H. Tu, Y.-W. Ma, "A Comprehensive Multi-Agent Deep Reinforcement Learning Framework with Adaptive Interaction Strategies for Contention Window Optimization in IEEE 802.11 Wireless LANs," *ICT Express*, 2025. DOI: 10.1016/j.icte.2025.01.010。

[5] C. H. Ke, C. A. Huang, K. W. Lin, "Achieving Fair Bandwidth Sharing for Downlink and Uplink Traffic in an Infrastructure WLAN", Journal of Chung Cheng Institute of Technology, vol. 42, no. 1, pp. 31-40, May 2013 (EI)

[6] A.B. Smith, C.D. Jones, and E.F. Roberts, “Article Title,” *Journal*, Vol., No, pp. 1-10, Date.

[7] pfrl,[Online].Avaliable:https://github.com/pfnet/pfrl

[8] F. Frommel, G. Capdehourat and F. Larroca, "Rein-forcement Learning Based Coexistence in Mixed 802.11ax and Legacy WLANs," 2023 IEEE Wireless Communications and Networking Conference (WCNC), Glasgow, United Kingdom, 2023,pp.1-6,doi: 10.1109/WCNC55385.2023.10119114.

[9] Tong, Q., Liang, G., & Bi, J. (2019). *Calibrating the Adaptive Learning Rate to Improve Convergence of ADAM*. arXiv preprint arXiv:1908.00700.